SW 캡스톤디자인 · 11월 1주 발표

WaferAI 배포 완료 보고

웨이퍼 결함 분류 서비스가 인터넷에 떠 있고, 실제 데이터로 전 기능을 검증했습니다

https://waferai-demo.eastasia.cloudapp.azure.com

항목	내용
팀	팀 Wafer-Eye · 조원곤, 변지민
기준 발표	10/01 5주차 (Phase 0 – 4, 테스트 126건, 서버 없음)
이번 보고 범위	10/02 – 11/03 · 커밋 19개 · Phase 5 – 6, 재학습, 배포, 계정 기능, 실서버 점검
작성일	2026년 11월 3일
발표 시간	약 8분 (쪽마다 "말할 것" 상자 기준, 시연 3분 포함)

1. 한 장 요약 — 지금 어디까지 왔나

97.74%	0.891	235건	65 / 65	28개
테스트 정확도 (학습에 안 쓴 17,504건)	테스트 macro-F1 (실제 분포)	자동 테스트 · CI 통과	실서버 기능 점검	API (설계 9개 모두 구현)

산출물 8단계	10/01 발표	지금
01 개발 환경	완료 · Docker 는 08단계로	완료 — Docker 구성, CI 에서 실제 빌드 · 기동 검증
02 DB 구축	테이블 5개	테이블 6개 — 재학습 작업, 모델 출처, 가입 승인 열
03 백엔드	API 18개 · 설계 9개 중 8개	API 28개 · 설계 9개 모두
04 프론트엔드	화면 8개 중 6개	8개 중 7개 — 모델 관리, 계정(가입 · 승인 · 초기화). 추이 그래프만 보류
05 시스템 통합	시나리오 11개 중 8개	실서버 65항목 점검 통과 — 업로드부터 재학습 요청까지
06 테스트	126건	235건 — SQLite · PostgreSQL 16, push 마다 CI
07 디버깅	버그 7	이후 14건 추가 수정
08 CI/CD · 배포	예정 (서버 확보 후)	배포 완료 — Azure, HTTPS, 자동 갱신, 배포 구성도 CI 검증

말할 것

10월 1일에는 서버도, 깨끗한 테스트 정확도도 없었습니다. 한 달 사이에 모델을 3분할로 다시 학습해 학습에 쓰지 않은 데이터로 97.74%를 확인했고, 서비스를 클라우드에 올려 HTTPS 주소로 누구나 접속할 수 있게 했습니다. 오늘은 ① 재학습 결과, ② 배포, ③ 새로 붙은 계정 기능, ④ 실제 데이터로 한 전 기능 점검을 순서대로 말씀드리고 마지막에 직접 시연하겠습니다.

2. 3분할 재학습 — "검증 정확도" 에서 "테스트 정확도" 로

10/01 발표의 96.45%는 학습과 섞인 검증 정확도였습니다(질문 Q1). 로트 단위로 train 80 / val 10 / test 10 을 나눠 ImageNet 가중치에서 새로 학습하고, 학습에 전혀 쓰지 않은 테스트 셋으로 쟀습니다.

	10/01 발표 (1학기 모델)	지금 (재학습 모델, 10/13 교체)
수치의 성격	검증 정확도 96.45% — 학습과 로트가 섞임	테스트 정확도 97.74% · macro-F1 0.891 (17,504건)
균형 표본	—	정확도 96.24% · macro-F1 0.918 (4,844건)
학습 환경	1학기 Colab	Colab T4 · 15에폭 78분 · 14에폭 선택 (검증 96.85%)
약한 클래스	Loc 0.868 · Donut 0.866	Loc 0.786 · Scratch 0.820 · Donut 0.839 (표본 32건)

	10/01 발표 (1학기 모델)	지금 (재학습 모델, 10/13 교체)
교체 판정	—	승격 스크립트가 직접 재서 통과 → ONNX 재생성 · 이전 모델 보관

판정 로직 효과 (새 모델 · 테스트 셋 · 확신도 0.80)

	실제 분포 17,504건	균형 4,844건
사람 검토 없이 나감	96.42% (그 안 정확도 99.23%)	94.65%
그중 틀린 건 / 전체	0.74% (130건)	1.51%
결함을 정상으로 내보냄	19건 (Edge-Loc 8 · Loc 5 · Scratch 3 · Center 3)	19건
검토 대기 (AI 정답률)	3.58% (57.7%)	5.35%

말할 것

숫자가 10/01 때보다 좋아 보이지만 성격이 다릅니다. 그때는 학습에 쓴 로트가 검증에도 섞인 값이었고, 지금은 한 번도 보지 않은 웨이퍼로 잰 값입니다. 발표의 "95% 통과 · 1.4% 오류" 도 같은 조건으로 다시 재니 94.65% · 1.51% 로 거의 같아서, 1학기 수치가 틀린 건 아니었다는 것까지 확인됐습니다. 모델의 확신도가 0.90 – 0.92 에 몰려 있다는 것도 이때 알았고, 그래서 설정 화면이 모델별 상한을 알도록 고쳤습니다.

3. 배포 — 인터넷에 떠 있는 서비스

항목	내용
주소	https://waferai-demo.eastasia.cloudapp.azure.com (HTTPS, Let's Encrypt 인증서 · 매주 자동 갱신)
서버	Azure for Students 크레딧(무료) · 홍콩 리전 · 2 vCPU · 4GB · Ubuntu 24.04
구성	Docker Compose 3컨테이너 — Nginx(화면 · 보안 헤더 · 프록시) / FastAPI(추론 · Grad-CAM) / PostgreSQL 16
실측	세 서비스 healthy 22초 · 예측 170 – 340ms · 첫 히트맵 1.0초 · API 메모리 1.05GB · 5건 동시 업로드 0.7초
검증	배포 절차서 7단계 · 사전 점검 스크립트 · 배포 후 확인 스크립트 8단계 — CI 가 push 마다 실제 Docker 로 같은 절차를 돌림
비용	크레딧 $100 에서 월 약 $30 — 1월 중순까지 운영 가능, 카드 등록 없음

왜 이 구성인가

- 서버는 학교 답을 기다리지 않고 학생 크레딧으로 — 카드 없이 받을 수 있고 발표일을 넘겨 쓸 수 있는 유일한 무료 경로였습니다. 한국 리전은 학생 구독에서 막혀 있어 가장 가까운 홍콩을 썼습니다(지연 50ms 안팎).
- HTTPS 가 필수 — 로그인 쿠키에 Secure 속성을 두어 HTTP 로는 브라우저가 쿠키를 저장하지 않습니다. Azure 의 무료 DNS 이름으로 인증서를 받았습니다.
- 모델 파일은 이미지에 넣지 않고 볼륨으로 — 재학습으로 모델을 바꿀 때 이미지를 다시 만들지 않습니다. 서버가 기동하며 새 모델을 등록하고 재학습 작업을 자동 완료합니다.

> 말할 것
>
> 이 주소는 지금 열립니다. 서버는 학교 지원 대신 Azure 학생 크레딧으로 확보했고 카드 없이 1월까지 돌아갑니다. 배포 절차는 GitHub Actions 가 push 할 때마다 실제 Docker 에서 똑같이 돌려 보기 때문에, 서버에서 처음 올릴 때 구성이 틀릴 가능성을 미리 없앴습니다. 실제로 서버 당일 막힌 것은 학생 구독의 리전 제한 하나뿐이었습니다.

4. 10/01 이후 추가된 기능

기능	내용	설계 근거
재학습 루프 (화면 5)	검토 500건 누적 시 자동 작업 · 관리자 수동 요청 · 학습 데이터 내려받기 · Colab 학습 · 승격 판정 · 교체 시 자동 완료	플로우차트 §5 재학습 트리거 — 설계 API 9개 중 마지막
계정 화면 (화면 8)	권한 배지 · 잠긴 사번 · 마지막 비밀번호 변경일(90일 경고) · 비밀번호 변경 · (관리자) 사용자 관리	UIUX 화면 8 명세 그대로
가입 신청 → 승인	로그인 화면에서 신청 → 승인 대기 → 관리자 승인. 승인 전 로그인하면 안내. 권한은 엔지니어로 시작	주소만 알면 누구나 들어오는 구조를 피함

기능	내용	설계 근거
비밀번호 찾기	관리자가 임시 비밀번호 발급(한 번만 표시) · 관리자 본인은 서버 명령	메일 발송 없이 쓰는 내부 시스템 방식
설정 상한	모델별 확신도 프로필 — 슬라이더 상한 = 모델 최대 확신도, 임계값별 예상 검토율 표시, 20% 넘으면 경고	0.92 를 넘기면 전부 검토로 가는 것을 측정으로 발견
오류 안내	입력 검증 실패를 항목 이름과 함께 한국어로 ("이메일 형식이 올바르지 않습니다")	사용자 피드백
로그인 보호 (11/04)	5회 실패 잠금(60초~15분) · IP 속도 제한 · 로그아웃 토큰 거부 · 비밀번호 변경 시 다른 기기 세션 종료 · 임시 비밀번호 강제 변경 · 비밀번호 규칙 · 감사 로그	OWASP 인증 체크리스트

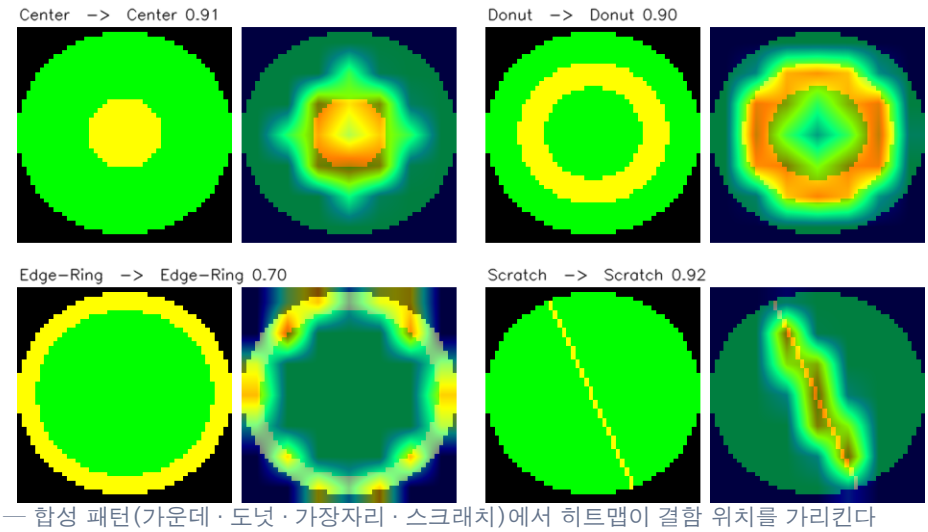
말할 것

기능 하나하나보다 공통점을 말씀드리면, 전부 "사람이 최종 확정한다" 는 이 시스템의 원칙을 따릅니다. 가입은 관리자가 승인하고, 비밀번호도 관리자가 초기화하고, 재학습 모델도 기준을 넘어야만 교체됩니다. 그리고 설정 상한처럼 측정에서 발견한 위험은 화면이 미리 막습니다.

5. 실제 데이터로 전 기능 점검 — 65항목 전부 통과

학습에 쓰지 않은 테스트 분할에서 실제 웨이퍼 12벌을 골라(클래스별 자동 통과 9 · 검토 대기 2 · Near-full 규칙 1) 네 가지 형식으로, 거절돼야 하는 입력 4개와 함께 운영 서버에 올렸습니다. 점검 스크립트(scripts/acceptance.py)가 로그인 없이 되는 것부터 재학습 요청까지 호출해 표로 보고합니다.

영역	확인한 것	결과
공개 경로	헬스체크 · CSP 헤더 · 비로그인 401 · 계정 존재 비노출 · 한국어 검증 메시지	6 / 6
업로드 · 판정	12벌 모두 정답 클래스 · 기대한 경로(자동 통과 / 검토 대기 / Near-full 규칙) · 170 – 340ms	12 / 12
입력 형식	npy · csv · json · png 같은 답 · 다른 색상표 · 깨진 파일 · 잘못된 값 거절 · 900px 축소 경고	5 / 5
결과 보기	목록 · 대기열 · 상세 · 썸네일 · 히트맵(1.0초 → 캐시 0.55초) · 2순위 히트맵	6 / 6
검토	1순위 승인 · 2순위 수정(AI 판정 보존) · 수동 라벨링 · 없는 클래스 거부	4 / 4
수석 · 관리자	임계값 · 상한 422 · 모델 목록 · 계정 생성 · 비활성화 · 초기화 · 가입 승인 · 권한 차단	21 / 21
재학습 · 동시성	요청 → 데이터 내려받기 → 실패 처리 · 5건 동시 업로드	5 / 5



Grad-CAM — 합성 패턴(가운데 · 도넛 · 가장자리 · 스크래치)에서 히트맵이 결함 위치를 가리킨다

말할 것

점검 중 틀어진 것은 다섯 건이었는데 모두 점검 스크립트의 기대값 실수였고 제품 결함은 없었습니다. 예를 들어 Near-full 웨이퍼는 확신도 0.91 이라 자동 통과를 기대했지만, 설계대로 밀도 규칙이 먼저 잡아 "규칙 확정" 으로 나왔습니다. 이 점검은 스크립트로 남겨 두어 다음에 무엇을 고쳐도 10분 안에 다시 돌릴 수 있습니다.

6. 시연 순서 (3분)

#	화면	할 것	보여줄 것
1	로그인	관리자로 로그인	HTTPS 주소, 가입 신청 링크, 비밀번호 안내
2	대시보드	samples/auto_Scratch_22185.png 업로드	이미지가 0/1/2 맵으로 복원되어 Scratch 93% 자동 통과
3	대시보드	samples/review_Loc_21258.npy 업로드	확신도 45% → 검토 필요 · 대기열 카운터 증가
4	상세	검토 필요 건 열기 → 히트맵 → 1순위 승인	원본 / 히트맵 / 겹쳐보기, 승인 후 대기 해제
5	대시보드	samples/bad_other_palette.png 업로드	다른 색상표는 이유와 함께 거절 (잘못 해석하지 않음)
6	설정	확신도 슬라이더를 92% 로	"검토 대기 약 98.7%" 빨간 경고 — 모델별 상한
7	모델 관리	운영 모델 · 테스트 성적 · 재학습 현황	분할 지문, 테스트 정확도, 500건까지 남은 수
8	계정	사용자 목록 · 승인 대기 · 초기화 버튼	가입 승인과 비밀번호 초기화

예비: 전시장 인터넷이 막히면 노트북에서 `python3 -m scripts.serve_preview` + `npm run dev` 로 같은 화면을 로컬에서 보여준다. samples/ 의 파일은 저장소에 있다.

7. 남은 일과 일정

시점	일	상태
11/18 – 19 전시회	시연 시나리오 확정 · 예비(로컬) 준비 · 동시 접속 부하 확인	시나리오 준비됨, 예비 미확인
12/03 최종 발표 전	보고서 · 발표 자료 최종본 (수치 확정)	10/13 보고서 이후 갱신 필요
12/03 최종 발표 전	1학기 설계 문서 정리 — 코드와 다른 부분 수정, 범위 밖(WaferNet · Streamlit · Sensor) 정리	미착수
선택	다른 색상표 이미지 지원(업로드 시 색 확인) · 화면 5 성능 추이 그래프	보류
결정 필요	Sensor AI — "이번 학기 범위 밖" 으로 명시	교수님 확인
이번 주	로그인 보호 패치 서버 반영 → 점검 스크립트 69항목 재실행	코드 · 테스트 완료, 배포 대기
발표 후	DB 백업 뒤 VM 정리 (크레딧 절약)	1월 중순 크레딧 소진

말할 것

기능 개발은 여기서 마무리하고, 남은 기간은 전시회 시연과 최종 산출물 정리에 씁니다. Sensor AI 는 1학기 설계에는 있었지만 Vision 을 서비스 수준으로 끝내는 쪽을 택했고, 범위 밖으로 정리해도 되는지 확인을 받고 싶습니다.

예상 질문

질문	답
97.74% 가 96.45% 보다 높은데 "더 엄격한 수치" 라는 게 무슨 뜻인가?	96.45% 는 학습 로트가 섞인 검증 값, 97.74% 는 한 번도 보지 않은 로트의 테스트 값이다. 같은 테스트 셋에서 1학기 모델은 98.19% 가 나오지만 그 샘플을 학습에 썼으므로 부풀려진 값이라 비교하지 않는다.
실물 웨이퍼 사진도 되나?	WM-811K 는 사진이 아니라 전기 검사 0/1/2 맵이다. 그 맵을 그린 이미지는 받지만 사진은 다른 과제다.
서버가 멈추면?	세 컨테이너 모두 자동 재시작, 상태 검사로 감시. 크레딧이 끝나면 멈추되 청구는 없다. 노트북 예비 구성도 있다.
회원가입을 왜 승인제로?	공장 품질 시스템이라 주소만 알면 누구나 들어오면 안 된다. 승인 전 로그인은 비밀번호가 맞을 때만 상태를 알려 계정 존재가 새지 않는다.
재학습은 실제로 돌려 봤나?	그렇다 — 이번 운영 모델이 그 결과다. 500건 누적 → 데이터 내려받기 → Colab 학습 → 승격 판정 → 교체 → 작업 자동 완료까지 끝까지 실행했다.
보안은 어디까지 봤나?	OWASP 인증 체크리스트로 점검했다. 계정 존재 비노출 · bcrypt · httpOnly 쿠키 · HTTPS · 보안 헤더는 이미 있었고, 이번 주에 연속 실패 잠금, IP 속도 제한, 로그아웃 토큰 무효화, 비밀번호 변경 시 다른 기기 세션 종료, 임시 비밀번호 강제 변경, 비밀번호 규칙, 감사 로그를 더했다.
테스트 235건은 무엇을 보나?	전처리 비트 일치, 판정 경계값, 인증 · 권한, DB 마이그레이션 왕복, Grad-CAM 위치, 배포 구성(.env 가 이미지에 안 들어가는지)까지. SQLite 와 PostgreSQL 양쪽에서 돈다.